
Practical Content-based Image Retrieval Handbook

基于内容的图像检索 实用手册



一本以实践经验为基础的图像检索指南书

整理：袁勇

整理时间：September 28, 2017

Email: yongyuanstu@gmail.com

Version: 2.00

目 录



1	简介	1
1.1	基于内容的图像检索技术	2
1.1.1	相同物体图像检索	2
1.1.2	相同类别图像检索	3
1.1.3	大规模图像检索特点	4
2	Python 及需要的安装包	6
2.1	NumPy 和 SciPy	6
2.1.1	Windows	6
2.1.2	OSX	7
2.1.3	Linux	7
2.2	Matplotlib	7
2.2.1	全平台	7
2.3	OpenCV	7
2.3.1	Windows 和 linux	8
2.3.2	OSX	8
2.4	Mahotas	8
2.4.1	全平台	8
2.4.2	跳过安装	8
3	载入、显示及保存	10
4	图像基础	13
5	特征编码	14
5.1	BoF 词袋模型	14
5.2	VLAD 局部聚合向量	14
5.3	Fisher Vector	15
5.3.1	VLAD	15
6	ANN 搜索	16
6.0.1	矩阵相乘	16
6.0.2	基于树的方法	16

6.0.3 哈希方法	16
6.1 拓展查询	17
参考文献	18





第 1 章 简介



在 Web2.0 时代，尤其是随着 Flickr、Facebook 等社交网站的流行，图像、视频、音频、文本等异构数据每天都在以惊人的速度增长。例如，Facebook 注册用户超过 10 亿，每月上传超过 10 亿的图片；Flickr 图片社交网站 2015 年用户上传图片数目达 7.28 亿，平均每天用户上传约 200 万的图片；中国最大的电子商务系统淘宝网的后端系统上保存着 286 亿多张图片。针对这些包含丰富视觉信息的海量图片，如何在这些浩瀚的图像库中方便、快速、准确地查询并检索到用户所需的或感兴趣的图像，成为多媒体信息检索领域研究的热点。基于内容的图像检索方法充分发挥了计算机长于处理重复任务的优势，将人们从需要耗费大量人力、物力和财力的人工标注中解放出来。经过十来年的发展，基于内容的图像检索技术已广泛应用于搜索引擎、电子商务、医学、纺织业、皮革业等生活的方方面面。

图像检索按描述图像内容方式的不同可以分为两类，一类是基于文本的图像检索 (TBIR, Text Based Image Retrieval)，另一类是基于内容的图像检索 (CBIR, Content Based Image Retrieval)。

基于文本的图像检索方法始于上世纪 70 年代，它利用文本标注的方式对图像中的内容进行描述，从而为每幅图像形成描述这幅图像内容的关键词，比如图像中的物体、场景等，这种方式可以是人工标注方式，也可以通过图像识别技术进行半自动标注。在进行检索时，用户可以根据自己的兴趣提供查询关键字，检索系统根据用户提供的查询关键字找出那些标注有该查询关键字对应的图片，最后将查询的结果返回给用户。这种基于文本描述的图像检索方式由于易于实现，且在标注时有人工介入，所以其查准率也相对较高。在今天的一些中小规模图像搜索 Web 应用上仍有使用，但是这种基于文本描述的方式所带来的缺陷也是非常明显的：首先这种基于文本描述的方式需要人工介入标注过程，使得它只适用于小规模的数据，在大规模图像数据上要完成这一过程需要耗费大量的人力与财力，而且随时不断外来的图像在入库时离不开人工的干预；其次，“一图胜千言”，对于需要精确的查询，用户有时很难用简短的关键字来描述出自己真正想要获取的图像；再次，人工标注过程不可避免的会受到标注者的认知水平、言语使用以及主观判断等的影响，因此会造成文字描述图片的差异。

随着图像数据快速增长，针对基于文本的图像检索方法日益凸现的问题，在 1992 年美国国家科学基金会就图像数据库管理系统新发展方向达成一致共识，即表示索引图像信息的最有效方式应该是基于图像内容自身的。自此，基于内容的图像检索技术便逐步建立起来，并在近十多年里得到了迅速的发展。典型的基于内容的图像检索基本框架如上图 1.1 所示，它利用计算机对图像进行分析，建立图像特征矢量描

述并存入图像特征库，当用户输入一张查询图像时，用相同的特征提取方法提取查询图像的特征得到查询向量，然后在某种相似性度量准则下计算查询向量到特征库中各个特征的相似性大小，最后按相似性大小进行排序并顺序输出对应的图片。基于内容的图像检索技术将图像内容的表达和相似性度量交给计算机进行自动的处理，克服了采用文本进行图像检索所面临的缺陷，并且充分发挥了计算机长于计算的优势，大大提高了检索的效率，从而为海量图像库的检索开启了新的大门。不过，其缺点也是存在的，主要表现为特征描述与高层语义之间存在着难以填补的语义鸿沟，并且这种语义鸿沟是不可消除的。

基于内容的图像检索技术在电子商务、皮革布料、版权保护、医疗诊断、公共安全、街景地图等工业领域具有广阔的应用前景。在电子商务方面，谷歌的 Goggles、阿里巴巴的拍立淘等闪拍购物应用允许用户抓拍上传至服务器端，在服务器端运行图片检索应用从而为用户找到相同或相似的衣服并提供购买店铺的链接；在皮革纺织工业中，皮革布料生产商可以将样板拍成图片，当衣服制造商需要某种纹理的皮革布料时，可以检索库中是否存在相同或相似的皮革布料，使得皮革布料样本的管理更加便捷；在版权保护方面，提供版权保护的服务商可以应用图像检索技术进行商标是否已经注册了的认证管理；在医疗诊断方面，医生通过检索医学影像库找到多个病人的相似部位，从而可以协助医生做病情的诊断.....基于内容的图像检索技术已经深入到了许许多多的领域，为人们的生活生产提供了极大的便利。

1.1 基于内容的图像检索技术

1.1.1 相同物体图像检索

相同物体图像检索是指对查询图像中的某一物体，从图像库中找出包含有该物体的图像。这里用户感兴趣的是图像中包含的特定物体或目标，并且检索到的图片应该是包含有该物体的那些图片。如 1.3 图所示，给定一幅“蒙娜丽莎”的画像，相同物体检索的目标就是要从图像库中检索出那些包含有“蒙娜丽莎”人物的图片，在经过相似性度量排序后这些包含有“蒙娜丽莎”人物的图片尽可能的排在检索结果的前面。相似物体检索在英文文献中一般称为物体检索 (Object Retrieval)，近似样本搜索或检测 (Duplicate Search or Detection) 也可以归类于相同物体的检索，并且相同物体检索方法可以直接应用到近似样本搜索或检测上。相同物体检索不论是在研究还是在商业图像搜索产业中都具有重大的价值，比如购物应用中搜索衣服鞋子、人脸检索等。

对于相同物体图像检索，在检索相同的物体或目标时，易受拍摄环境的影响，比如光照变化、尺度变化、视角变化、遮挡以及背景的杂乱等都会对检索结果造成较大的影响，图 1.3 左图给出了这几种变化的例子，此外，对于非刚性的物体，在进行检索时，物体的形变也会对检索结果造成很大的影响。

由于受环境干扰比较大，因而对于相同物体图像检索，在选取特征的时候，往往



会选择那些抗干扰性比较好的不变性局部特征，比如 SIFT1、SURF2、ORB3 等，并以此为基础通过不同的编码方式构建图像的全局描述，具有代表性的工作有词袋模型 4(BoW, Bag of Words)、局部特征聚合描述符 5(VLAD, Vector of Locally Aggregated Descriptors) 以及 Fisher 向量 6(FV, Fisher Vector)，这一类以类 SIFT 为基础的图像检索方法，由于结合了类 SIFT 不变性的特性，并且采用了由局部到全局的特征表达方式，并且在实际应用时在提取 SIFT 的时候还可以使用 siftGPU 加速 SIFT 提取，因而从整体上来说能够获得比较好的检索效果，但这一类方法通常其特征维度往往是非常高的，如图 1.2 所示，在牛津建筑物图像数据库上采用词袋模型进行检索，为了获得较高的检索精度，在聚类时聚类数目一般都设置到了几十万，因而其最终表示的特征其维度高达几十万维，因此为它们设计高效的索引方式显得十分必要。

1.1.2 相同类别图像检索

对给定的查询图片，相似图像检索的目标是从图像库中查找出那些与给定查询图像属于同一类别的图像。这里用户感兴趣的是物体、场景的类别，即用户想要获取的是那些具有相同类别属性的物体或场景的图片。为了更好的区分相同物体检索和相同类别检索这两种检索方式区，仍以图 1.3 左图所举的“蒙娜丽莎”为例，用户如果感兴趣的就是“蒙娜丽莎”这幅画，那么检索系统此时工作的方式应该是以相同物体检索的方式进行检索，但如果用户感兴趣的并不是“蒙娜丽莎”这幅画本身，而是“画像”这一类图片，也就是说，用户所感兴趣的已经是对这幅具体的画进行了类别概念的抽象，那么此时检索系统应该以相同类别检索的方式进行检索。相同类别图像检索目前已广泛应用于图像搜索引擎，医学影像检索等领域。

对于相同类别图像检索，面临的主要问题是属于同一类别的图像类内变化巨大，而不同类的图像类间差异小。如图 1.3 右图所示，对于“湖泊”这一类图像，属于该类别的图像在表现形式上存在很大的差异，而对于图?????? 右图下面所示的“dog”类和“woman”类两张图像，虽然它们属于不同的类，但如果采用低层的特征去描述，比如颜色、纹理以及形状等特征，其类间差异非常小，直接采用这些特征是很难将这两者分开的，因此相同类别图像检索在特征描述上存在着较大的类内变化和较小的类间差异等挑战。近年来，以深度学习 (DL, Deep Learning) 为主流的自动特征在应用到相同类别图像检索上时，能够极大的提高检索的精度，使得面向相同物体的检索在特征表达方面得到了较好的解决。目前，以卷积神经网络 (CNN, Convolutional Neural Network) 为主导的特征表达方式也开始在相同物体图像检索上进行展开，并已有了一些相应的工作 7，但由于相同物体在构造类样本训练数据时并不像相同类别图像检索那样那么方便，因而相同物体图像检索在 CNN 模型训练以及抽取自动特征等方面还有待深入。不管是相同物体图像检索还是相同类别图像检索，在使用 CNN 模型提取自动特征的时候，最终得到的维度一般是 4096 维的特征，其维度还是比较高的，直接使用 PCA 等降维的手段，虽然能达到特征维度约减的目的，但在保持必要的检索精度前提下，能够降低的维度还是有限的，因而对于这一类图像检索，同样



有必要为它构建够高效合理的快速检索机制，使其适应大规模或海量图像的检索。

1.1.3 大规模图像检索特点

无论是对于相同物体图像检索还是相同类别图像检索，在大规模图像数据集上，它们具有三个典型的主要特征：图像数据量大、特征维度高以及要求相应时间短。下面对这三个主要特征逐一展开说明：

(1) 图像数据量大。得益于多媒体信息捕获、传输、存储的发展以及计算机运算速度的提升，基于内容的图像检索技术经过十几年的发展，其需要适用的图像规模范围也从原来的小型图像库扩大到大规模图像库甚至是海量图像数据集，比如在上世纪九十年代图像检索技术发展的早期阶段，研究者在验证图像检索算法性能的时候，用得比较多的是 corel1k，该图像库共 1000 张图片，与今天同样可以用于图像检索的最流行的图像分类库 imageNet 数据集相比，其量级已经有了成千上万倍的增长，因而图像检索应满足大数据时代的要求，在大规模图像数据集上应该具备伸缩性。

(2) 特征维度高。图像特征作为直接描述图像视觉内容的基石，其特征表达的好坏直接决定了在检索过程中可能达到的最高检索精度。如果前置特征未表达好，在构建后置检索模型的时候，不但会复杂化模型的构建，增加检索查询的响应时间，而且能够提升的检索精度也是极其有限的。所以在特征提取之初，应该有意识的选取那些比较高层特征。如果将局部特征表达方式也作为“高维”的一种，那么特征的描述能力跟特征的维度高低具有较大的关联，因而在特征描述方面大规模图像检索具有明显的特征维度高的特性，比如词袋模型 BoW、VLAD、Fisher 向量以及 CNN 特征。为了对这些高维的特征有一个维度量级的定量认识，本文以词袋模型构建的特征向量为例，在牛津大学建筑物图像数据集上试验了特征维度（在数值上跟聚类单词数目大小相等）对检索精度的影响，从图 1.2 中可以看到，词袋模型的特征维度是非常高的。因此，面向大规模图像数据集检索的另一个典型特点是图像特征描述向量维度高。

(3) 要求响应速度快。对于用户的查询，图像检索系统应该具备迅速响应用户查询的能力，同时由于大规模图像数据量大、特征维度高，直接采用暴力搜索 (Brute Search) 索引策略（也称为线性扫描）难以满足系统实时性的要求，图 1.2 右图所示的是在牛津大学建筑物图像数据集上平均每次查询所耗费的时间，可以看到在图像数量仅有 4063 张的牛津大学建筑物图像集，其查询时间在单词数目为 100 万且重排深度为 1000 的条件下就需要耗费 1 秒左右的时间，并且整个程序还是运行在一台高配的服务器上，因此，大规模图像检索需要解决系统实时响应的问题。

基于哈希的图像检索技术其具体框架如图 1.4 所示，按步骤可以分为特征提取、哈希编码、汉明距离排序以及重排四个步骤：

(1) 特征提取。对图像数据库中的图像逐一进行特征提取，并将其以图像文件名和图像特征——对应的方式添加到特征库中；

(2) 哈希编码。哈希编码可以拆分成为两个子阶段，在对特征进行编码之前需要有哈希函数集，而哈希函数集则通过哈希函数学习阶段而得到，因此这两个子阶



段分别为哈希函数学习阶段和正式的哈希编码阶段。在哈希函数学习阶段，将特征库划分成训练集和测试集，在训练库上对构造的哈希函数集 $H(x)=h_1(x), h_2(x), \dots, h_K(x)$ 进行训练学习；正式的哈希编码阶段时，分别将原来的特征 $x_i(i=1, 2, \dots, N)$ 代入到学习得到的哈希函数集 $H(x)$ 中，从而得到相应的哈希编码。值得注意的是，如果设计的哈希算法已经经过实验验证有效，那么在实际的应用系统中，在划分数数据集的时候，可以将整个图像库既作为训练集也作为图像数据库，从而使得在大规模图像上学到的哈希函数具备较好的适应性；

(3) 汉明距离排序。在汉明距离排序阶段，对于给定的查询图像，逐一计算查询图像对应的哈希编码到其他各个哈希编码之间的汉明距离，然后按从小到大的顺序进行相似性排序，从而得到检索结果；

(4) 重排。针对步骤 (3) 汉明排序后的结果，可以选择前 $M(M \ll N)$ 个结果或者对汉明距离小于某一设置的汉明距离 d_{cdc} 的结果进行重排。一般地，在重排的时候采用欧式距离作为相似性度量得到重排后的结果。因此，从这里可以看到，哈希过程可以看作是筛选候选样本或是粗排序的过程。在采用哈希方法进行大规模图像检索的应用系统中，通常会有重排这一步，但是在设计哈希算法的时候，对性能进行指标评价直接采用的是汉明距离，也就是在评价哈希算法性能的时候，不需要重排这一步。

随着视觉数据的快速增长，面向大规模视觉数据的基于内容的图像检索技术不论是在商业应用还是计算机视觉社区都受到了极大的关注。传统的暴力 (brute-force) 搜索方法 (又称线性扫描) 通过逐个与数据库中的每个点进行相似性计算然后进行排序，这种简单粗暴的方式虽然很容易实现，但是会随着数据库的大小以及特征维度的增加其搜索代价也会逐步的增加，从而使得暴力搜索仅适用于数据量小的小规模图像数据库，在大规模图像库上这种暴力搜索的方式不仅消耗巨大的计算资源，而且单次查询的响应时间会随着数据样本的增加以及特征维度的增加而增加，为了降低搜索的空间复杂度与时间复杂度，在过去的十几年里研究者们找到了一种可供替代的方案——近似最近邻 (ANN, Approximate Nearest Neighbor) 搜索方法，并提出了很多高效的检索技术，其中最成功的方法包括基于树结构的图像检索方法、基于哈希的图像检索方法和基于向量量化的图像检索方法。



第 2 章 Python 及需要的安装包



要探索计算机视觉世界，首先我们需要安装一些安装包。作为探索计算机视觉之旅的起始，要安装这些安装包特别是 OpenCV 是非常冗余乏味的，它依赖于你所使用的操作系统。我已经试着将这些安装说明简化成了一份简短的使用指南，不过，正如你所了解的，锁着项目、网站的改变，这些安装说明是会变化的！如果你在安装中遇到了问题，确保查看安装包的网站以获得最新安装说明。

我强力推荐你要么用 `easy_install` 或 `pip` 来管理你那些安装包。它会使你的生活变得更简单！

最后，如果你不想自己逐一安装这些安装包的话，我已经预先安装好后所有需要的安装包，并把它们放在一个 Ubuntu 的虚拟机里。使用该虚拟机可以使你跳过那些繁琐的安装包的安装，直接进入本书的实例中，而不必理会这些安装包的管理、安装说明以及编译错误。

要想获得更多这个预先配置好的虚拟机，可以前往<http://www.pyimagesearch.com/practical-python-opencv/>查看详细信息。

现在，让我们来安装这些安装包！

2.1 NumPy 和 SciPy

NumPy 是一个用于 Python 编程语言的库，它对大型多维数组提供支持。为什么 NumPy 很重要呢？原因是使用 NumPy，我们可以将图像表示为一个多维数组。将图像表示为 NumPy 数组，不仅易于计算和资源得以有效利用，而且一些其他的图像处理操作和机器学习库也是用 NumPy 数组来表示的。此外，使用 NumPy 内置的高水准数学函数，我们能在了一幅图像上做快速数值分析。

与 NumPy 形影不离的是 SciPy。SciPy 为科学和技术计算提供了更多的支持。

2.1.1 Windows

到目前为止，在你的 Windows 系统上安装 NumPy 和 SciPy 最简单的方式是<http://www.scipy.org/install.html>下载并安装二进制分发版。

2.1.2 OSX

如果你运行的是 OSX 10.7.0(Lion) 或更高版本，NumPy 和 SciPy 已经预先安装好了。

不过，我喜欢安装 ScipySuperpack。它包含了最新版的 NumPy、SciPy、Matplotlib 和其他非常有用的安装包，比如 ipython、pandas 和 scikit-learn。所有的这些安装包是值得安装的，并且如果你在www.PylImageSearch.com上阅读我的博客，你会发现这些安装包我用得非常的频繁。

2.1.3 Linux

很多 Linux 发行版，比如 Ubuntu，都预先安装有 NumPy 并且已经是配置好了的。

如果你想要最新版的 NumPy 和 SciPy，你可以从源代码进行编译，不过最简单的方法还是用一个包管理器，比如在 Ubuntu 上用 apt-get。

2.2 Matplotlib

用一句简洁的话概括，matplotlib 是一个绘图库。如果你以前用过 MATLAB，在 matplotlib 环境里你很可能会觉得非常的舒适。在分析图像的时候，我们会用到它。不管是画图像直方图还是只是简单地查看图像本身，matplotlib 是一个非常有用的工具，你值得将它纳入到你的工具箱中。

2.2.1 全平台

Matplotlib 可以在<http://matplotlib.org/>上下载。如果你已经安装了 ScipySuperpack，那么 Matplotlib 就已经在你的计算机上安装了。你也可以通过 easy_install 或 pip 来安装它。

此外，在 matplotlib 官网上还提供了 Windows 的二进制安装文件。

2.3 OpenCV

如果说 NumPy 的主要目标是用于有效地表示大型多维数组，那么，OpenCV 的主要目标便是实时处理图像。该库从 1999 年发布以来，已随处可见，直到在 2009 年发布的第 2 版中我们才看到了它对 NumPy 的支持。OpenCV 这个库本身是用 C/C++ 写的，但在运行该安装包时它提供了 Python 的绑定。OpenCV 是我手下最喜欢的计算机视觉库，在本书中，我们会经常使用它。

OpenCV 的安装是常常会变化的。由于这个库是用 C/C++ 写的，所以在编译的时候需要特别的注意，并确保预先要安装的东西都已安装。由于 OpenCV 的最新



安装说明是经常会改变的，所以在安装 OpenCV 时要确保自己去查看 OpenCV 的网站<http://opencv.org/>。

2.3.1 Windows 和 linux

OpenCV 文档提供了在 Windows 和 Linux 用二进制版本安装 OpenCV 非常棒的教程，你可以在这里看到它的安装说明http://docs.opencv.org/doc/tutorials/introduction/table_of_content_introduction/table_of_content_introduction.html#table-of-content-introduction。

2.3.2 OSX

过去数年，在 OSX 上安装 OpenCV 是一件很痛苦的事，幸运的是现在它的安装已变得越来越简单。你需要安装 cmake 来构建并编译该 OpenCV 库，你可以从这里下载 cmake<http://www.cmake.org/cmake/help/install.html>。

安装 cmake 后，你就可以从 SourceForge 资源库检查源代码并进行编译。一般情况下，我发觉 Guilherme Defreitas 关于怎样在 OSX 上安装 OpenCV 的说明是非常棒的，并且为 OpenCV 的学习给出了一个很好的开始。

你可以在这里找到他的说明：<http://www.guidefreitas.com/installing-opencv-2-4-2-on-mac-osx-mountain-lion-with-python-support>。

2.4 Mahotas

如 OpenCV 一样，Mahotas 也依赖于 NumPy 数组。很多在 Mahotas 中实现的函数都可以在 OpenCV 中找到，不过在某些情况下，Mahotas 接口比 OpenCV 接口更容易使用，我们将用 Mahotas 作为 OpenCV 的补充。

2.4.1 全平台

在不同的平台上安装 Mahotas 是极其容易的。假设你已经安装了 NumPy 和 SciPy，那么你所有需要做的只是运行 `pip install mahotas` 或 `easy install mahotas`。

既然我们已经安装了所有我们需要的安装包，现在就让我们开始探索计算机视觉世界之旅吧！

2.4.2 跳过安装

正如我在前面提到过，安装这些安装包是费时且繁琐的。如果你想跳过上面那些安装过程而直接进入图像处理和计算机视觉世界，我已经打包好了一个预先配置好了的 Ubuntu 虚拟机，该虚拟机安装好了上面提到的所有安装包。



如果你对该虚拟机感兴趣并且想要下载它的话（它能够节省你很多时间并避免很多麻烦），你可以到这里下载<http://www.pyimagesearch.com/practicalpython-opencv/>。



第 3 章 载入、显示及保存



这本书的初衷是成为一本实用手册，用于指引怎样用 Python 和 OpenCV 来开始计算机视觉编程。本着这样一条信念，那就让我们不要浪费任何时间了。拿起你的键盘开始写些简单的代码，用于从磁盘载入一幅图像，在屏幕上显示它，并将它用不同的格式写入一个文件。在执行该代码的时候，我们的 Python 脚本应该可以在屏幕上显示我们载入的图像，正如图 3.1 所示。

首先，我们创建一个名为 `load_display_save.py` 来包含我们的代码，现在我们可以开始写代码了：

列表 3.1: `load_display_save.py`

```
1 import argparse
2 import cv2
3
4 ap = argparse.ArgumentParser()
5 ap.add_argument("-i", "--image", required = True,
6                 help = "Path to the image")
7 args = vars(ap.parse_args())
```

我们要做的第一件事是导入在这个例子中我们需要的包。我们用了 `argparse` 来解析我们的命令行参数。然后，导入 `cv2` - 这里 `cv2` 就是我们的 OpenCV 库，它包含了我们需要的图像处理函数。

上面代码第 4-7 行用于解析命令行参数。这里我们需要的唯一一个参数是 `-image`：磁盘上图像所在的路径。最后，我们解析这些参数，并在它们保存在一个字典中。

列表 3.2: `load_display_save.py`

```
1 image = cv2.imread(args["image"])
2 print "width: %d pixels" % (image.shape[1])
3 print "height: %d pixels" % (image.shape[0])
4 print "channels: %d" % (image.shape[2])
5
6 cv2.imshow("Image", image)
7 cv2.waitKey(0)
```

既然我们有了图像所在的路径，在第 8 行我们就可以用 `cv2.imread` 函数从磁盘载入该图像。`cv2.imread` 函数返回一个 NumPy 数组，用于表示一幅图像。

第 9-11 行检查图像的维数。由于图像是用 NumPy 数组来表示的，我们可以用 `shape` 属性来检查该图像的宽、高，以及颜色通道数。




图 3.1: 载入并在屏幕上显示一幅霸王龙图像的例子

最后，第 13 行和第 14 行用于在屏幕上显示实际载入的图像。cv2.imshow 的第一个参数是一个字符串，是窗口的“名字”；第二个参数是我们在第 8 行从磁盘载入的图像。最后调用了 cv2.WaitKey 函数来暂停运行的脚本，直到我们在键盘上按下一个键。用参数“0”表示按下任意一个键就会释放暂停。

最后，我们将该幅图像以 JPG 的格式写入文件中：

列表 3.3: load_display_save.py

```
1 cv2.imwrite("newimage.jpg", image)
```

要运行上面的脚本并显示出图片，我们只需要打开终端窗口，并执行下面的命令：

列表 3.4: load_display_save.py

```
1 $ python load_display_save.py --image ../images/trex.png
```

如果不错什么问题的话，你应该可以在你的屏幕上看到图 3.1 中的霸王龙。要终止脚本的运行的话，只需要在图像窗口上单击，并按下任意键。

检查上面脚本的输出结果，你应该可以看到图片的一些基本信息。你会看到对于那张霸王龙图片，它的宽是 350 个像素，高是 228 个像素，以及 3 个颜色通道 (R、G、B 三个颜色通道)。用一个 NumPy 数组表示的话，该数组大小为 (350,228,3)。

当我们在写矩阵时，通常我们会将它们写成这种形式： $\# \text{行} \times \# \text{列}$ ——但对于 NumPy，便不是这样的了。NumPy 通常会先给出列数，然后才是行数。这点，你要牢牢记住。

最后，注意文件夹里的内容。你会看到有一个新文件在那儿：newimage.jpg。



OpenCV 会自动地为我们将 PNG 格式的图片转换为 JPG 格式图片！所以在图像格式间进行转换时我们并不需要费什么劲。

下一章，我们将探索怎样在一幅图像上获取像素值并对像素值进行操作。



第 4 章 图像基础



在这一章中，我们将审查图像的积木——像素。我们将详细的讨论什么是像素，以及像素是怎样形成一幅图像的，并且怎么在 OpenCV 里对这些像素进行操作。

每幅图像由像素集组成。像素是一幅图像的原材料，积木。它是图像的最小单元。

一般情况下，像素通常采用两种方式进行表示：灰度和彩色。在灰度图像中，每一个像素的像素值在 0 到 255 之间，“0”代表“黑色”，“1”表示“白色”。

第 5 章 特征编码



BoW (Bag of visual word)、VLAD (Aggregating local descriptors) 以及 FV (Fisher Vector) 是三种非常经典的将局部特征表示成全局特征的编码方法，在图像检索领域，这图像检索领域，这三种编码方法是必须面对的三名剑客。下面是小白菜结合自己的理解，对这三种编码方法的原理和一些实践经验的总结。

5.1 BoF 词袋模型

基于 SIFT 局部特征的 BOF 模型非常适合于做 Object retrieval, 下面是自己在 oxford building 数据库 (5063 张图片) 上进行的一些实验。表格中单词数目为聚类时设定的聚类数目，以及是否采用 SIFT 或者 rootSIFT，rootSIFT 怎么计算的可以阅读 Object retrieval with large vocabularies and fast spatial matching 这篇文章，空间校正即在重排的时候，对错配的 SIFT 点对进行剔除，剔除的方法可以采用 RANSAC 或者类 RANSAC 方法，详细介绍可以阅读 SIFT(ASIFT) Matching with RANSAC，检索精度采用平均检索精度 (mean Average Precision, mAP)，其计算过程可以阅读信息检索评价指标这篇文章。下面需要注意的是查询时间单次查询的结果，并没有进行多次查询进行平均，此外查询时间是查询和计算 mAP 时间的总和。

5.2 VLAD 局部聚合向量

在进行理论分析之前，先来看看 VLAD 长个什么样子，这里本小子分步展开 VLAD 是怎么得来的。

提取 SIFT 特征。对于一个样本数为 N 的数据库，先对图像库中的所有图像提取 SIFT 描述子，假设提取到了所有 SIFT 描述子数目为 n ，用 X 来表示的话， X 就是一个 $n \times 128$ 的矩阵。聚类生成词汇向量。假设要生成 K 个单词，对 X 直接用 Kmeans 聚成 K 类，类中心即为单词 (也叫码字)。生成 VLAD 向量。这一步其实如果对 BOW 的生成过程清楚的话，这一步理解起来就非常简单了。BoW 统计的是描述子落入最近单词里的数目，而 VLAD 统计的则是这些落入最近单词里与该单词的累积残差。根据 Aggregating local image descriptors into compact codes 的描述：

BOW 做的是描述子的 0 阶统计分布，而 FV 则是扩展了的 BOW 的高阶统计。这里引出来的 FV 是什么呢？VLAD 是 FV 的特例，这里我们先不关注 FV，我们只要借此推得 VLAD 是 BOW 的高阶统计就行。

经过上面三个步骤后，一幅图像可以用一个 1(K128) 维的向量表示。为了初步验证上面的过程是否正确，来看看上面那篇论文中 VLAD 的维数是否如这里所理解的是一个 1(K128) 维的向量，直接看实验表：

5.3 Fisher Vector

每幅图像由像素集组成。像素是一幅图像的原材料，积木。它是图像的最小单元。

一般情况下，像素通常采用两种方式进行表示：灰度和彩色。在灰度图像中，每一个像素的像素值在 0 到 255 之间，“0”代表“黑色”，“1”表示“白色”。

5.3.1 VLAD

每幅图像由像素集组成。像素是一幅图像的原材料，积木。它是图像的最小单元。

一般情况下，像素通常采用两种方式进行表示：灰度和彩色。在灰度图像中，每一个像素的像素值在 0 到 255 之间，“0”代表“黑色”，“1”表示“白色”。



第 6 章 ANN 搜索



6.0.1 矩阵相乘

6.0.2 基于树的方法

几乎所有的 ANN 方法都是对全空间的划分，所以基于树的方法也不例外。基于树的方法采用树这种数据结构的方法来表达对全空间的划分，其中又以 KD 树最为经典。下面左图是 KD 树对全空间的划分过程，以及用树这种数据结构来表达的一个过程。

对 KD 树选择从哪一维度进行开始划分的标准，采用的是求每一个维度的方差，然后选择方差最大的那个维度开始划分。这里有一个比较有意思的问题是：为何要选择方差作为维度划分选取的标准？我们都知道，方差的大小可以反映数据的波动性。方差大表示数据波动性越大，选择方差最大的开始划分空间，可以使得所需的划分面数目最小，反映到树数据结构上，可以使得我们构建的 KD 树的树深度尽可能的小。为了更进一步加深对这一点的认识，可以以一个简单的示例图说明：

假设不以方差最大的 x 轴为划分面 (

$$x_{var} = 16.25$$

)，而是以 y 轴 (

$$y_{var} = 0.0$$

) 轴为划分面，如图中虚线所示，可以看到，该划分使得图中的四个点都落入在同一个子空间中，从而使得该划分成为一个无效的划分，体现在以树结构上，就是多了一层无用的树深度。而以 x 轴为初始划分则不同 (图像实线所示)，以 x 轴为初始划分可以得到数据能够比较均匀的散布在左右两个子空间中，从而使得整体的查找时间能够最短。注意，在实际的 kd 树划分的时候，并不是图中虚线所示，而是选取中值最近的点。上面示意图构建的具体 kd 树如下所示：

一般而言，在空间维度比较低的时候，KD 树是比较高效的，当空间维度较高时，可以采用下面的哈希方法或者矢量量化方法。

6.0.3 哈希方法

哈希，顾名思义，就是将连续的实值散列化为 0、1 的离散值。在散列化的过程中，对散列化函数 (也就是哈希函数) 有一定的要求。根据学习的策略，可以将哈希方法分为无监督、有监督和半监督三种类型。在评估某种哈希方法用于图像检索的检索精

度时，可以使用 knn 得到的近邻作为 ground truth，也可以使用样本自身的类别作为 ground truth。所以在实际评估准确度的时候，根据 ground truth 的定义，这里面是有一点小的 trick 的。通常对于无监督的哈希图像检索方法，由于我们使用的都是未标记的数据样本，所以我们会很自然的采用 knn 得到的近邻作为 ground truth，但是对于图像检索的这一任务时，在对哈希函数的构造过程中，通常会有“相似的样本经编码后距离尽可能的近，不相似的样本编码后则尽可能的远”这一基本要求，这里讲到的相似，指语义的相似，因而你会发现，编码的基本要求放在无监督哈希方法里，似乎与采用 knn 得到的近邻作为 ground truth 的评价方式有些南辕北辙。对无监督哈希方法的 ground truth 一点小的疑惑在小白菜读书的时候就心存这样的困惑，一直悬而未解。当然，在做无监督的图像哈希方法，采用样本自身的类别作为 ground truth 是毋庸置疑的。

小白菜读书那会儿，研究了很多的哈希图像检索方法（见 hashing-baseline-for-image-retrieval），有时候总会给一些工程实践上的错觉（在今天看来是这样的），即新论文里的方法远远碾压经典的方法，那是不是在实际中这些方法就很 work 很好使。实践的经历告诉小白菜，还是经典的东西更靠谱，不是因为新的方法不好，而是新的事物需要经过时间的沉淀与优化。

所以，这里不会对近两年的哈希方法做铺陈，而是聊一聊工程中在要使用到哈希方法的场景下一般都会选用的局部敏感哈希（Local Sensitive Hashing, LSH）。

6.1 拓展查询

拓展查询 (QE, Query Expansion): 指对返回的前 top@K 个结果，包括查询样本本身，对它们的特征求和取平均，再做一次查询，此过程称为拓展查询。

从上面的定义可以看出，拓展查询属于重排的一种方式。通过 Query Expansion，以达到提高检索召回率的目的。前面的博文 RANSAC 算法做直线拟合曾介绍过 RANSAC 的基本思想，放在词袋模型里（相应博文见图像检索：BoW 图像检索原理与实战），我们可以使用 RANSAC 方法或 Weak Geometry Consistency 方法做几何校正，进行重排以提高检索的精度。在这篇博文中，小白菜暂时抛开其他的重排方法，重点分析 Query Expansion 对图像检索精度的提升。

根据小白菜读图像检索论文获得的对 Query Expansion 的感知，做完 Query Expansion 能够获得百分之几的精度提升。为了证实 Query Expansion 对检索精度的改善，在过去一段时间里，小白菜在 Oxford Building 数据库上对其做了验证。下面是小白菜对 Query Expansion 的实验整理和总结。



参考文献

